

Devoir à la maison

Convergence de la statistique χ^2 .

Exercice1

Une urne contient des boules numérotées de 1 à d. la proportion des boules de numéro i est p_i , avec $p_i > 0$.

On note P le vecteur de composantes $p_i : i = 1, \dots, d$. On tire n boules avec remise. Soient Y_n le numéro tiré au n -ième tirage. X_n le vecteur aléatoire de composantes $X_n(i) = 1_{\{Y_n=i\}}$. Soit $S_n(i)$

Le nombre de boules de numéro i tirées en n tirages et S_n le vecteur aléatoire de de composantes $S_n(i)$ pour $i = 1, \dots, d$.

1. Vérifier que $X_n(i) \sim B(p_i)$, $S_n(i) \sim B(n, p_i)$. (ce qui implique que :

$$E(X_n(i)) = p_i, \text{var}(X_n(i)) = p_i(1 - p_i), \quad E(S_n(i)) = np_i \text{ et } \text{var}(S_n(i)) = np_i(1 - p_i).$$

2. vérifier que l'espérance du vecteur X_n est P et que sa matrice de variance covariance est

$$D - PP' \text{ où } D = \text{diag}(p_i). \text{ C'est-à-dire } D = \begin{pmatrix} p_1 & \cdots & \\ \vdots & \ddots & \vdots \\ & \cdots & p_d \end{pmatrix}$$

3. Soit $\Sigma_n = \sqrt{n}(\frac{S_n}{n} - P)$ utiliser le théorème de la limite centrale vectorielle pour vérifier que : $\Sigma_n \xrightarrow{\text{En loi}} G = N_d(0, D - PP')$.

4. Soit $T_n = n \sum_{i=1}^d (\frac{S_n(i)}{n} - p_i)^2 / p_i$

Nous voulons montrer que $T_n \xrightarrow{\text{En loi}} \chi^2(d-1)$ pour cela soit Z le vecteur aléatoire de composantes

$$G(i)/\sqrt{p_i} \quad i = 1, \dots, d. \text{ Soit } Z = \begin{pmatrix} G(1)/\sqrt{p_1} \\ \vdots \\ G(d)/\sqrt{p_d} \end{pmatrix} T_n$$

- a) Vérifier que $Z = MG$ avec $M = \begin{pmatrix} 1/\sqrt{p_1} & \cdots & \\ \vdots & \ddots & \vdots \\ \cdots & 1/\sqrt{p_d} \end{pmatrix}$ et $G = \begin{pmatrix} G(1) \\ \vdots \\ G(d) \end{pmatrix}$.

$$\text{b) Soit } v_d = \begin{pmatrix} \sqrt{p_1} \\ \vdots \\ \sqrt{p_d} \end{pmatrix}$$

-Vérifier que $\Gamma_Z = M\Gamma_G M' = MDM' - MPP'M'$.

-Vérifier que $MDM' = I_d$, $MPP'M' = v_d v_d'$ en déduire que $\Gamma_Z = I_d - v_d v_d'$.

$$5. \text{ soit } Z_n = \begin{pmatrix} \Sigma_n(1)/\sqrt{p_1} \\ \vdots \\ \Sigma_n(d)/\sqrt{p_d} \end{pmatrix}.$$

- a) vérifier que $T_n = \sum_{i=1}^d \left[\sqrt{n} \left(\frac{S_n(i)}{n} - p_i \right) / p_i \right]^2 = \sum_{i=1}^d [\Sigma_n(i)/\sqrt{p_i}]^2 = f(Z_n) = \|Z_n\|^2$

où $f(x) = \sum_{i=1}^n x_i^2$.

c) Vérifier que $Z_n = M\Sigma_n$ et utiliser 3. 4a) pour montrer que $Z_n \xrightarrow{\text{En loi}} Z$ en déduisant que :

$$\|Z_n\|^2 \xrightarrow{\text{En loi}} \|Z\|^2 \text{ soit } T_n \xrightarrow{\text{En loi}} \|Z\|^2.$$

d) Soit V une $d \times d$ matrice orthogonale réelle dont la dernière ligne est v_d'

-donner la loi du vecteur aléatoire VZ .

-comparer $\|VZ\|^2$ et $\|Z\|^2$ en déduire que $T_n \xrightarrow{\text{En loi}} \chi^2(d-1)$. qui est le résultat cherché.

On a démontré ainsi le théorème suivant :

Théorème : Soit $\{X_1, \dots, X_n\}$ un échantillon d'une loi P à valeurs dans $\{1, \dots, I\}$.

Posons $p_i = P(\{i\})$ et $N_n(i) = \sum_{j=1}^n 1_{(X_j=i)}$ Alors :

$$T_n = \sum_{i=1}^I \left(\frac{N_n(i) - np_i}{\sqrt{np_i}} \right)^2 \xrightarrow{\text{En loi}} \chi^2(I-1)$$

Exercice2

Définition : Soient P et Q deux lois à valeurs dans $\{1, \dots, I\}$. Posons $p_i = P(\{i\})$ et $q_i = Q(\{i\})$.

La quantité $\chi^2(P, Q) = \sum_{i=1}^I \frac{(p_i - q_i)^2}{p_i}$ est appelée distance de χ^2 entre P et Q .

On considère deux n -échantillons $\{X_1, \dots, X_n\}$ et $\{Y_1, \dots, Y_n\}$ des lois de deux variables aléatoires X et Y à valeurs dans $\{1, \dots, I\}$ et $\{1, \dots, J\}$ respectivement.

La loi empirique du couple (X, Y) est donnée par : $\hat{P}_n(i, j) = N_n(i, j)/n$

où $N_n(i, j) = \sum_{k=1, l=1}^n 1_{(X_k=i, Y_l=j)}$. On veut tester l'indépendance de X et Y .

Si elles sont indépendantes. la loi du couple est le produit des lois marginales.

Donc $H_0: "P_{i,j} = P_i P_j. 1 \leq i \leq I \text{ et } 1 \leq j \leq J"$ contre $H_1: \text{il existe } (i,j) \text{ tel que: } P_{i,j} \neq P_i P_j$. avec

$P_i = \sum_{j=1}^J P_{i,j}$ et $P_j = \sum_{i=1}^I P_{i,j}$. Sous H_0 la loi empirique s'écrit $\bar{P}_n(i, j) = N_n(i, \cdot) N_n(\cdot, j) / n^2$.

Utiliser le théorème ci-dessus pour montrer que :

$\chi^2(\hat{P}_n, \bar{P}_n)$ converge vers $\chi^2((I-1)(J-1))$ sous H_0 et $+\infty$ sous H_1 .

Déduire de ce résultat le test d'indépendance de χ^2 , qui est le suivant :

On rejette H_0 si $\chi^2(\hat{P}_n, \bar{P}_n) \geq \chi^2_{(I-1)(J-1), \alpha}$ quantile d'ordre $1 - \alpha$ de la loi $\chi^2((I-1)(J-1))$.

Exercice3

Un utilisant le tableaux contingence :

1. Vérifier que $N_n(i, j) = n_{ij}$ et que $\bar{P}_n(i, j) = n_{i.} n_{.j} / n^2$, et $t_{ij} = n \bar{P}_n(i, j)$.
2. En déduire que $\chi^2(\hat{P}_n, \bar{P}_n) = \sum_{i,j}^{I \times J} (n_{ij} - t_{ij})^2 / t_{ij}$. et en déduire le résultat du cours.

3.